Proyecto 2: *Sistema de detección, segmentación y clasificación de fracturas pélvicas a partir de tomografía computarizada*

Miguel David Arroyo
Annie Sofia Correa Delgado
Fabian Andrés Gomezcasseres
Juan Andrés Hoyos
Daniela Marín Villacorte
2026

1. Introducción

Las fracturas pélvicas se asocian a una discapacidad superior al 50 % y a una mortalidad superior al 13 % [1, 2]. Planificar su reducción exige identificar en la tomografía computarizada (TC) cada fragmento, el hueso al que pertenece y su separación del fragmento principal, una segmentación que a mano toma hasta una hora por caso [1]. Automatizarla es difícil porque el número, la forma y la posición de los fragmentos varían entre pacientes, y muchos están en contacto entre sí [2, 3]. Los métodos recientes guían la red con la distancia a la superficie de fractura [2, 3] o con contexto global [4]. En el challenge PENGWIN, el mejor método, volumétrico, alcanzó un IoU por fragmento de 0,930, aunque los fragmentos pequeños y los que están en contacto siguen siendo la principal fuente de error [1].

Proponemos un sistema 2.5D ligero, entrenado con los 100 casos públicos de TC de PENGWIN: tres modelos, uno por plano anatómico, que detectan el sacro y los coxales, segmentan cada fragmento, lo asignan a su hueso y miden su distancia al principal en milímetros. Lo evaluamos en 20 casos de prueba frente a SAM.

2. Método

Datos y preprocesamiento (Fig. 1a). Usamos los 100 casos públicos de TC de PENGWIN, divididos por paciente en 75 de entrenamiento, 5 de validación y 20 de prueba (semilla 42). Cada volumen se lleva a orientación canónica LPS, ya que el 34 % venía en RAS. Después se aplica una ventana de hueso (centro 400 HU, ancho 1800 HU), se realza el contraste con Otsu y CLAHE y se ajusta a 256 × 256 conservando la proporción. La entrada es 2.5D: el corte y sus dos vecinos forman tres canales, lo que aporta contexto 3D con el costo de una red 2D.

Arquitectura (Fig. 1b y 1c). El backbone es propio (FundidoraPC+): cuatro bloques convolucionales y un bloque de contexto con convoluciones dilatadas, que lleva el campo receptivo de 46 a 238 píxeles. Sobre él, un CBAM con compuerta residual realza el hueso frente al tejido blando. La red tiene dos ramas. La de detección es una cabeza en rejilla de 16 × 16 celdas, seguida de un NMS propio por clase que conserva una caja por región, ya que en un corte hay a lo sumo un sacro y dos coxales. La de segmentación es un decoder con conexiones de salto que, guiado por esas cajas, produce la máscara semántica, un mapa de centros y desplazamientos (x, y). Cada píxel se asigna al centro al que apunta, lo que separa los fragmentos de un hueso sin fijar su número de antemano. Por último, una cabeza de pertenencia asigna cada fragmento al sacro, al coxal izquierdo o al coxal derecho.

En la app, cada fragmento toma la clase semántica mayoritaria del decoder, que en prueba rinde igual (F1 0,888 frente a 0,886). No se usa YOLO, Detectron2 ni Mask R-CNN: la rejilla de detección, el NMS y el decoder son implementaciones propias.

Pérdida. La pérdida total, en la **Ec. (1),** suma la de detección y la de segmentación. La detección combina objetividad (BCE), caja (L1 + 1 − IoU) y clase (entropía cruzada), con $\lambda_{obj} = 0{,}46$, $\lambda_{caja} = 2{,}90$ y $\lambda_{clase} = 2{,}03$, elegidos entre cuatro

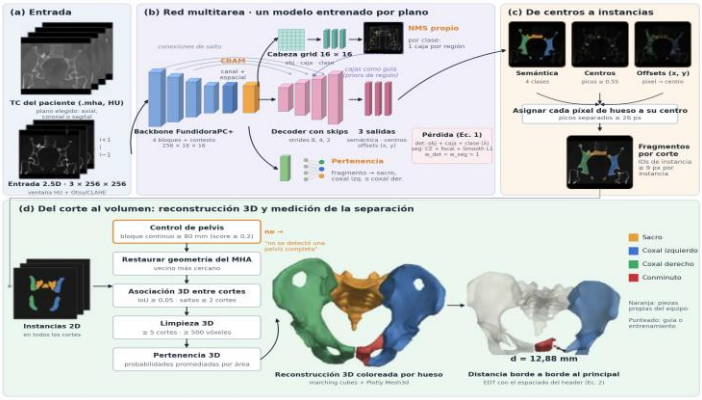


Fig. 1. *Sistema propuesto. (a) Cada estudio entra como pila de cortes 2.5D. (b) Red multitarea, entrenada una vez por plano: detección en rejilla con NMS propio, decoder guiado por las cajas y cabeza de pertenencia. (c) Las instancias se obtienen asignando cada píxel de hueso al centro al que apuntan sus offsets. (d) Tras el control de pelvis, las instancias 2D se unen en fragmentos 3D y se mide la distancia de cada conminuto al fragmento principal.*

configuraciones con tres semillas por igualar la magnitud inicial de los tres términos. La detección y la segmentación pesan lo mismo ($w_{det} = w_{seg} = 1$), igual que los tres términos de segmentación: ambas tareas solo se entrenan juntas en la etapa C, que cambia la mAP y el Dice en menos de 0,01, así que un barrido de estos pesos aportaría poco.

$$\mathcal{L} = w_{det}\left[\lambda_{obj}\mathcal{L}_{obj} + \lambda_{caja}(\mathcal{L}_{L1} + 1 - \mathrm{IoU}) + \lambda_{clase}\mathcal{L}_{CE}\right] + w_{seg}\left[\mathcal{L}_{sem} + \mathcal{L}_{centro} + \mathcal{L}_{off}\right] \quad (1)$$

En la **Ec. (1)**, $\mathscr{L}_{\mathrm{sem}}$ es la entropía cruzada sobre cuatro clases (fondo, sacro y los dos coxales), $\mathscr{L}_{\mathrm{centro}}$ es una pérdida focal sobre el mapa de centros y $\mathscr{L}_{\mathrm{off}}$ es una Smooth L1 sobre los desplazamientos, calculada solo en los píxeles de hueso.

Entrenamiento. Se entrena con AdamW, OneCycle y precisión mixta en cuatro etapas: (A) detección, (B) decoder con el resto de la red congelado y (C) toda la red con tasa de aprendizaje 3×10^{-4}, de 10 épocas cada una, y (D) cabeza de pertenencia con el resto congelado, hasta 40 épocas con parada temprana. Los modelos finales usan los pesos de la etapa B, porque C no mejora lo bastante para justificar su costo

Tres planos y salida 3D (Fig. 1d). Entrenamos el mismo diseño tres veces, sobre cortes axiales, coronales y sagitales. En los dos últimos se remuestrea a píxel cuadrado, y el sagital recibe un cuarto canal con la posición lateral del corte, para distinguir izquierda de derecha. Cada modelo recorre el volumen corte a corte y entrega probabilidades por clase; las de los tres planos se promedian con igual peso y se toma el argmax. Los fragmentos de cada hueso son los componentes conexos 3D de al menos 500 mm³ (umbral fijado en validación), y el principal es el de mayor volumen. La distancia de cada conminuto al fragmento principal de su hueso se mide con una transformada de distancia euclidiana (distance_transform_edt) y el espaciado físico del encabezado, en milímetros.

$$d(F) = \min_{p \in F} \mathrm{EDT}_s\,(\neg M)(p), \quad s = (s_x, s_y, s_z)\ \mathrm{mm} \quad (2)$$

En la **Ec. (2)**, F es el fragmento conminuto y M el principal; un fragmento en contacto tiene d = 0. La misma medida se calcula sobre la referencia para compararlas.

3. Resultados

Todas las cifras corresponden a los 20 casos de prueba.

Métricas frente a las metas. Los modelos axial y sagital cumplen 6 de las 7 metas; el coronal, 4 **(Tabla 1)**. La detección supera con amplitud sus metas en los tres planos (mAP@0.50 de 0,87 a 0,93). La meta que ningún plano alcanza es el Dice por fragmento (0,74 a 0,79 frente a 0,85). A nivel semántico, el modelo supera a SAM por 15 a 20 puntos de Dice. La inferencia toma 28,9 ms por imagen en GPU (RTX 5060) y 102,5 ms en CPU.

***Tabla 1**. Métricas en prueba (20 casos). En negrita, las que no cumplen la meta.*

Métrica	Meta	Axial	Coronal	Sagital
F1 macro de pertenencia	≥ 0,85	0,886	**0,819**	0,888
AUC macro de pertenencia	≥ 0,85	1	1	1
IoU de cajas	≥ 0,65	0,855	0,787	0,852
mAP@0.50	≥ 0,65	0,933	0,866	0,918
mAP@[0.50:0.95]	≥ 0,40	0,692	0,555	0,711
Dice por fragmento	≥ 0,85	**0,793**	**0,739**	**0,79**
IoU por fragmento	≥ 0,70	0,704	**0,636**	0,715
Dice semántico: modelo / SAM	—	0,962 / 0,803	0,953 / 0,756	0,954 / 0,806
IoU semántico: modelo / SAM	—	0,927 / 0,672	0,910 / 0,608	0,912 / 0,674

Reconstrucción 3D. La fusión de los tres planos (pesos de la etapa B) alcanza un Dice 3D de 0,973 (sacro 0,959; coxal izquierdo 0,978; derecho 0,981) frente a 0,958 del axial solo, y mejora en los 20 casos de prueba. Las predicciones en cortes sin pelvis bajan de 4,1 % a 0,8 %. Con piezas de al menos 500 mm³ se predicen 65 fragmentos, con precisión 0,969 y recall 0,553: los 60 principales y 3 de los 54 conminutos (PQ 0,610 frente a 0,568 del axial). El Dice 3D se mide sobre todo el volumen, por lo que no es comparable con el Dice por corte de la Tabla 1.

Ablación. Para aislar el efecto de CBAM y del aprendizaje por transferencia (TL, desde Oxford-IIIT Pet), entrenamos cuatro variantes del modelo axial con las etapas A y B y comparamos con intervalos de confianza al 95 % por bootstrap pareado por paciente (Tabla 2). Casi todas las diferencias son menores de 0,01; la excepción consistente es quitar CBAM, que empeora todas las métricas (Dice −0,008, mAP −0,011; significativo en IoU). El TL no mejora al entrenamiento desde cero.

***Tabla 2**. Ablación en prueba (modelo axial, etapas A y B).*

CBAM	TL	Dice por fragmento	F1 pertenencia	mAP@0.50
sí	no	0,791	0,884	0,936
no	no	0,783	0,878	0,925
sí	sí	0,795	0,88	0,928
no	sí	0,786	0,876	0,932

Pertenencia. En el sistema completo (Fig. 2a), casi no hay confusión entre huesos: 78 de 16.041 fragmentos, el 0,5 %. El error dominante es no encontrar el fragmento: el 27 % de los del sacro, el 15 % de los del coxal izquierdo y el 17 % de los del coxal derecho. Cuando la cabeza de pertenencia recibe las máscaras reales (Fig. 2b), acierta el 99 % en las tres clases (F1 0,988 frente a 0,886). El límite del sistema está, por tanto, en la segmentación y no en la clasificación. La cobertura depende del tamaño: se encuentra el 57 % de los fragmentos de menos de 100 píxeles y el 90 % de los de 400 a 1.599.

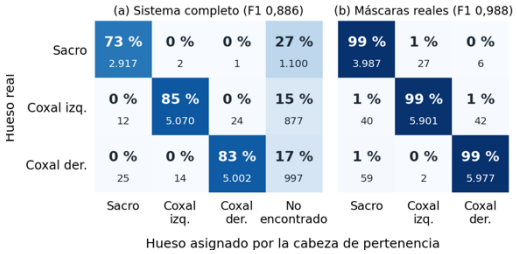


***Fig. 2**. Matriz de confusión de la pertenencia en prueba (modelo axial, 16.041 fragmentos). (a) Sistema completo; "no encontrado" son los fragmentos que la segmentación no recupera. (b) Clasificación con las máscaras reales, sin errores de segmentación.*

Distancia de separación. De los 54 conminutos de prueba, 48 (89 %) están en contacto con el fragmento principal en la referencia (d = 0) y 6 están separados. La mayoría de los primeros se fusiona con el principal, lo que da la distancia correcta por construcción (error medio de 0,58 a 0,65 mm) y no indica que se hayan encontrado; el resto no se detecta. De los 6 separados, ninguno se recupera como fragmento independiente en el modelo axial, y en los que se fusionan el error es de 6,7 a 8,6 mm. Los fragmentos principales se identifican en 58 a 60 de 60.

***Tabla 3.** Distancia predicha frente a la referencia en prueba (54 conminutos).*

Plano	Fusionados	Omitidos	Error medio (mm)	Error en los 6 separados (mm)
Axial	52	2	0,65	6,7
Coronal	50	4	0,58	7,2
Sagital	43	11	0,6	8,6

Cinco peores casos. Los cinco cortes con peor Dice en prueba (Fig. 3) tienen Dice 0 y no son fracturas complejas: son extremos de un hueso o astillas delgadas de la cresta ilíaca, con fragmentos de 9 a 33 píxeles. En

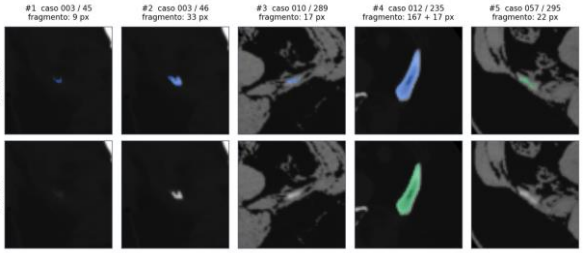


***Fig. 3.** Los cinco peores cortes de prueba (modelo axial). Arriba, la referencia; abajo, la predicción. Azul: coxal izquierdo; verde: coxal derecho.*

cuatro, el detector encuentra la caja pero el decoder no produce máscara; en el quinto la máscara es correcta pero se asigna al coxal contrario, al verse una sola ala ilíaca. Estos cortes explican parte de la brecha entre el Dice por fragmento (0,79) y el semántico (0,96), pues cada fragmento diminuto pesa igual que uno grande. SAM, con las mismas cajas, recupera algunos (Dice 0,53 a 0,89 en los casos 1, 2 y 4), lo que sugiere que el límite está en la decodificación y no en la detección.

4. Discusión

Fragmentos en contacto.

El sistema no separa los conminutos que tocan al principal, el 89 % de los de prueba. Descartamos dos posibles causas. El armado 3D no lo es: con las instancias reales de cada corte la reconstrucción reproduce los fragmentos (F1 1,0), y relajar la absorción y el umbral de centros en validación solo hizo aparecer 3 de 12 conminutos, a costa de pasar de 16–23 a 26–120 fragmentos predichos frente a 27 reales. Tampoco bastan los tres planos: su fusión recupera 3 de los 54 conminutos de prueba, pues un fragmento en contacto forma un solo componente conexo con el principal. Esto sugiere que la información para distinguirlos no está en la máscara predicha, y separarlos probablemente requiere modelar la superficie de fractura [2, 3] o trabajar en 3D [1]. Mientras tanto, para estos fragmentos el sistema mide d = 0 mm, correcto respecto a la referencia, pero no los identifica como piezas propias.

Limitaciones. La arquitectura es 2.5D, frente a los modelos volumétricos que lideran el challenge [1]. Los umbrales, la configuración 3D y los checkpoints se eligieron con solo 5 casos de validación y una semilla. En el plano coronal, la etapa C empeoró a la B (Dice −0,018, significativo). No se probó, por ejemplo, un tórax completo.

5. Conclusiones

Presentamos un sistema 2.5D multitarea que detecta, segmenta y asigna los fragmentos de una pelvis fracturada en TC y mide su separación en milímetros. En 20 casos de prueba cumple 6 de las 7 metas en los planos axial y sagital, y supera a SAM por 15 a 20 puntos de Dice. La meta pendiente es el Dice por fragmento (0,79 frente a 0,85): su límite está en separar fragmentos pequeños o en contacto, no en clasificarlos, y esa es la dirección natural para mejorarlo.

6. Referencias

[1]. Y. Sang, Y. Liu, S. Yibulayimu, *et al.*, "Benchmark of segmentation techniques for pelvic fracture in CT and X-ray: Summary of the PENGWIN 2024 challenge," arXiv:2504.02382v2, 2025.

[2]. Y. Liu, S. Yibulayimu, Y. Sang, *et al.*, "Preoperative fracture reduction planning for image-guided pelvic trauma surgery: A comprehensive pipeline with learning," *Medical Image Analysis*, vol. 102, p. 103506, 2025.

[3]. B. Zeng, H. Wang, L. Joskowicz y X. Chen, "Fragment distance-guided dual-stream learning for automatic pelvic fracture segmentation," *Computerized Medical Imaging and Graphics*, vol. 116, p. 102412, 2024.

[4]. F. Ju, J. Zhu, Y. Wu y J. Zhao, "HDFSN: A hybrid dynamic fracture segmentation network based on pelvic CT images," *Computers & Graphics*, vol. 131, p. 104311, 2025.